SISTEMAS INTELIGENTES (PET1702)

Projeto 1 - Modelo de Regressão Linear Múltipla para a Análise do Dataset UCI CCPP

Componentes: **JEFFERSON BEZERRA DA GAMA (2025022550)**
LAVÍNIA DANTAS DE MESQUITA (2025022536)

I. OBJETIVO

O presente projeto teve como objetivo construir e avaliar um modelo de regressão linear múltipla para prever a produção de energia elétrica (PE) de uma usina termoelétrica de ciclo combinado, com base em variáveis ambientais. Além disso, buscou-se analisar a relação entre as variáveis por meio de correlação, identificar possíveis problemas de multicolinearidade e avaliar o desempenho do modelo utilizando métricas estatísticas.

II. PARTE TEÓRICA

A regressão linear múltipla, exigida pelo projeto, é uma técnica estatística utilizada para modelar a relação entre uma variável dependente e duas ou mais variáveis independentes. Neste caso, o modelo assume uma relação linear entre essas variáveis, sendo representado por uma equação da forma:

Produção de Energia Elétrica(PE) = Coeficiente0 + Coeficiente1 x Temperatura Ambiente(AT) + Coeficiente2 x Vácuo de Escape(V) + Coeficiente3 x Pressão Atmosférica(AP) + Coeficiente4 x Umidade Relativa(RH) + Erro(ε)

A análise de correlação foi utilizada para verificar o grau de relação linear entre as variáveis, auxiliando na identificação das mais relevantes para o modelo, e além disso, foi considerada a possível presença de multicolinearidade, que ocorre quando variáveis independentes apresentam alta correlação entre si, podendo afetar a estabilidade dos coeficientes do modelo.

III. PARTE PRÁTICA

Inicialmente, foi realizada a importação do dataset "Combined Cycle Power Plant" diretamente do repositório UCI, utilizando a biblioteca ucimlrepo. As variáveis independentes (AT, V, AP, RH) e a variável dependente (PE) foram organizadas em um único DataFrame para facilitar a análise.

```
# Faz o download do dataset, 294 = repositório UCI
dataset = fetch_ucirepo(id=294)

# X = Variáveis independentes (features)
# AT (temperatura), V (vácuo), AP (pressão), RH (umidade)
# Y = Variável dependente (target)
# PE (produção de energia elétrica)
X = dataset.data.features
y = dataset.data.targets

# Unificar em um único DataFrame
df = X.copy()
df['PE'] = y

df.head()
```

Fonte: Autoria Própria

Em seguida, foi realizada uma análise exploratória dos dados, incluindo a verificação de valores nulos, estatísticas descritivas e a construção de uma matriz de correlação. Essa etapa permitiu identificar que a variável AT apresenta forte correlação negativa com a produção de energia, onde pode-se usar esse valor de forma inversa.

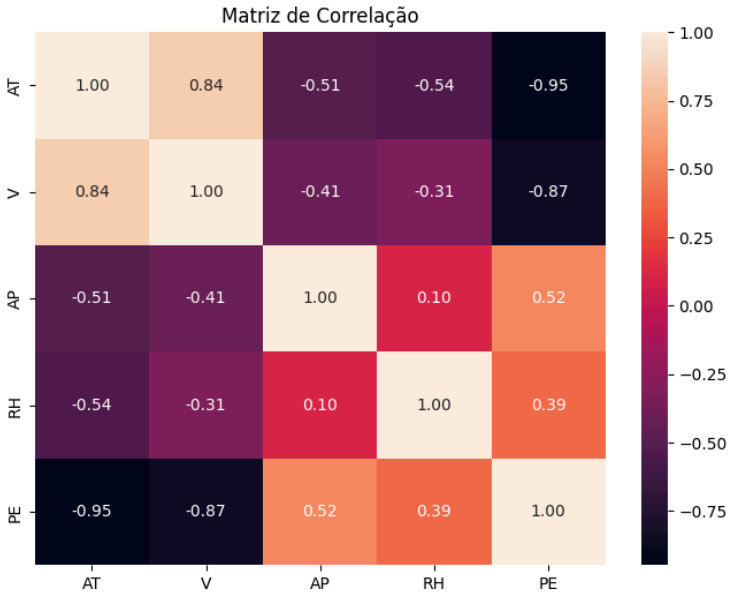

Fonte: Autoria Própria

Visto que havia uma influência forte de V, foi analisada também a correlação entre as variáveis independentes, sendo identificada uma forte relação entre AT e V, indicando possível multicolinearidade. No entanto, optou-se por manter ambas no modelo, uma vez que a multicolinearidade não passou dos 0.90.

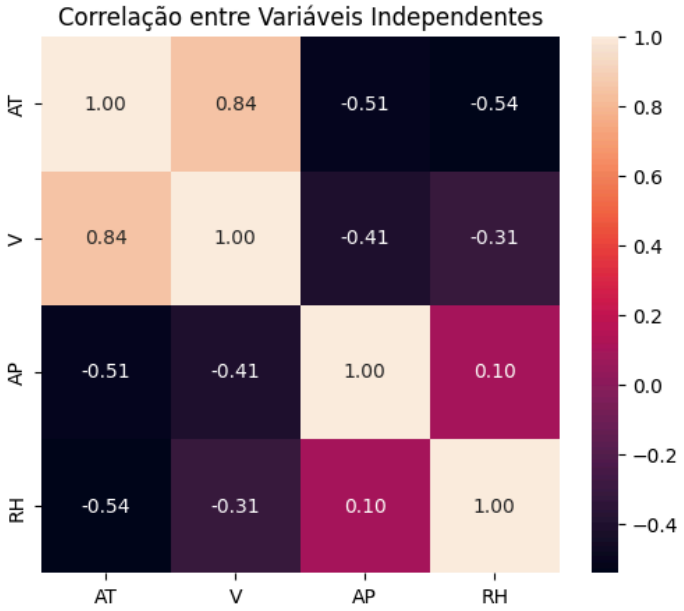

Fonte: Autoria Própria

Para a construção do modelo, os dados foram divididos em conjuntos de treino (80%) e teste (20%), utilizando a função train_test_split. Em seguida, foi aplicado o modelo de regressão linear múltipla por meio da biblioteca scikit-learn.

```
# Dividindo os dados (80% treino, 20% teste)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)
# Definindo o modelo de regressão linear
modelo = LinearRegression()
# Treinando o modelo
modelo.fit(X_train, y_train)
# Organização dos coeficientes numa tabela
coeficientes = pd.DataFrame({
    'Variável': X.columns,
```

```
    'Coeficiente': modelo.coef_.flatten()
})
coeficientes
```

Fonte: Autoria Própria

	Variável	Coeficiente
0	AT	-1.985900
1	V	-0.232094
2	AP	0.062200
3	RH	-0.158118

Fonte: Autoria Própria

Por fim, o modelo foi avaliado utilizando métricas de desempenho como MAE, RMSE e R^2, além da análise gráfica dos valores reais versus previstos, onde os resultados obtidos foram os seguintes:

MAE: 3.595913178273408 - RMSE: 4.502633229532186 - R^2: 0.9301046431962188

Primeiramente, a avaliação do modelo de regressão linear múltipla demonstrou resultados satisfatórios na previsão da produção de energia elétrica, onde o coeficiente de determinação ($R^2 = 0.93$) indica que o modelo é capaz de explicar aproximadamente 93% da variabilidade dos dados, evidenciando uma forte capacidade preditiva.

Ademais, os valores de erro obtidos, MAE (3.59) e RMSE (4.50), mostraram-se baixos em relação à escala da variável alvo, indicando que as previsões estão, em média, próximas dos valores reais, e sua proximidade indica ausência de erros significativos.

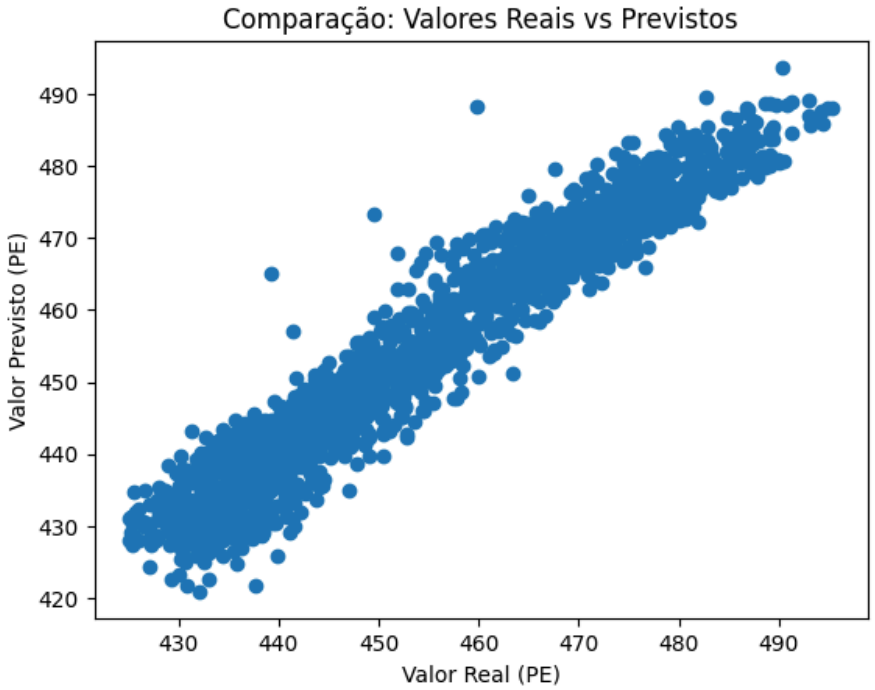

Já a análise por meio do gráfico de dispersão entre valores reais e previstos apenas reforça esses resultados, apresentando uma distribuição dos pontos próxima de uma linha diagonal, o que indica forte concordância entre os dados observados e as previsões do modelo.

IV. CONCLUSÕES

A partir dos resultados obtidos, foi possível identificar as variáveis mais relevantes, destacando a temperatura ambiente como o principal fator de influência. Apesar da presença de multicolinearidade entre algumas variáveis, o impacto não comprometeu o desempenho do modelo, onde conclui-se que o modelo de regressão linear múltipla é adequado e eficaz para o problema proposto, sendo capaz de realizar previsões com alta precisão.

Como trabalhos futuros, sugere-se a aplicação de modelos mais complexos e a utilização de técnicas adicionais, como análise de VIF e métodos não lineares, para aprimorar ainda mais os resultados.

REFERÊNCIAS

UCI Machine Learning Repository. **Combined Cycle Power Plant Dataset**. Disponível em: https://archive.ics.uci.edu/

RINICHristy**. *Combined Cycle Power Plant Dataset (UCI Data)*.** Disponível em: https://www.kaggle.com/datasets/rinichristy/combined-cycle-power-plant-data-set-uci-data. Acesso em: 12 abr. 2026.

Pedregosa et al. **Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research**, 2011.

SOUZA, Pedro Thiago Valério de. **Intelligent Systems**. Disponível em: https://github.com/pedrothiag/intelligent-systems/tree/main/slides. Acesso em: 08 abr. 2026.